

Proyecto Final de Aprendizaje Automático

Alumno: Gallego, Ian Samuel

Fecha: 31/05/2026

1. Contexto y relevancia del problema

La motivación de este proyecto surge de la intersección entre mi formación previa en el rubro de la construcción como Maestro Mayor de Obra y mis estudios actuales en Ciencia de Datos. El objetivo fue buscar un caso de estudio que conectara ambos mundos, enfocándome en el análisis de un e-commerce de ferretería y materiales de construcción radicado en Tierra del Fuego. Dado que, por cuestiones de confidencialidad, no fue posible utilizar los datos transaccionales directos de la empresa, tomé la decisión de construir un dataset sintético, para no desviarme de mi idea inicial. Este conjunto de datos replica fielmente las lógicas comerciales y el contexto fueguino, sirviendo como base de desarrollo para un modelo reproducible en otros negocios que deseen implementar esta solución con sus propios datos.

A partir de mi experiencia y de conversaciones con el área comercial, identifiqué que la base de clientes en este rubro es altamente heterogénea. Coexisten constructores profesionales, grandes empresas, comercios revendedores y clientes particulares (B2C) que realizan compras puntuales para refacciones hogareñas. Sin embargo, las acciones de marketing actuales (promociones, campañas de mailing, mensajes por WhatsApp) se ejecutan de manera masiva y uniforme. Esta falta de segmentación genera varios problemas:

- **Desperdicio de presupuesto:** Se ofrecen descuentos a clientes que tenían intención de compra asegurada.
- **Baja conversión:** Los mensajes carecen de relevancia para gran parte de la audiencia, lo que disminuye las tasas de apertura.
- **Fuga de clientes:** No existen mecanismos preventivos para detectar clientes valiosos inactivos ni acciones para retenerlos.
- **Subutilización del segmento B2B:** No se aprovecha el potencial de los clientes de gran volumen mediante programas de fidelización o trato premium.

La relevancia de este problema se potencia en el contexto de Tierra del Fuego, donde la estacionalidad de la construcción es muy marcada (concentrada en primavera y verano) y la brecha entre el ticket de un cliente B2B y uno B2C es de varios órdenes de magnitud. Una segmentación inteligente permitiría optimizar el presupuesto, mejorar la retención y personalizar la experiencia. Según diversos estudios de marketing digital, la personalización basada en datos puede incrementar las tasas de conversión entre un **10%** y un **30%**, representando un impacto comercial significativo. Dentro de los estudios más conocidos y mencionamos encontramos tales como;

1. McKinsey & Company

- **Reporte:** *The value of getting personalization right—or wrong—is multiplying*
- **Enlace:** [Leer artículo en McKinsey.com](#)
- Aquí encontrarás el desglose sobre cómo la personalización bien ejecutada genera un 40% más de ingresos y mejora drásticamente la eficiencia del marketing.

2. Salesforce (Evergage)

- **Reporte:** *2020 Trends in Personalization* (Publicado originalmente por Evergage junto a Researchscape, antes de la integración total con Salesforce Marketing Cloud).
- **Enlace:** [Ver el reporte original en PDF](#)
- En la página 15 del reporte puedes ver el gráfico exacto donde el 97% de los profesionales reportan un impacto medible, y se detallan las mejoras de conversión superiores al 10% y al 30%.

3. HubSpot

- **Artículo / Análisis:** *Landing page personalization: An implementation guide* (Donde citan su análisis histórico de las llamadas a la acción).
- **Enlace:** [Leer artículo en el Blog de HubSpot](#)
- En la sección número 1 ("Call-to-action"), citan directamente su análisis propio de más de 330.000 CTAs durante un periodo de seis meses, validando que las versiones personalizadas rinden un 202% mejor que las estáticas.

2. Objetivos

Objetivo General

Desarrollar un modelo de aprendizaje automático no supervisado que permita segmentar a los clientes del e-commerce en grupos homogéneos según su comportamiento de compra. Se utilizará la metodología RFM (Recency, Frequency, Monetary) combinada con algoritmos de clustering, con el fin de diseñar y habilitar estrategias de marketing personalizadas y accionables.

Objetivos Específicos

- **Preparación de datos:** Construir y acondicionar el dataset histórico mediante limpieza, tratamiento de valores nulos, detección de outliers y normalización.
- **Ingeniería de características:** Calcular las variables RFM (R, F, M) para cada cliente e incorporar variables complementarias clave para el rubro (diversidad de categorías, ticket promedio, antigüedad y tipo de cliente inferido B2B/B2C).
- **Análisis Exploratorio (EDA):** Analizar la distribución y correlación de las variables para comprender el comportamiento general de la cartera.
- **Evaluación de modelos:** Implementar y comparar distintos algoritmos de clustering para determinar la segmentación más coherente y útil. El

número óptimo de clusters (K) se definirá mediante el método del codo y el coeficiente de silueta.

- **Interpretación comercial:** Perfilar cada segmento obtenido (ej. "Clientes de Alto Consumo", "En riesgo", "Ocasionales") y proponer estrategias de marketing diferenciadas, estimando su impacto potencial.

3. Tipo de problema

El presente trabajo aborda un problema de **aprendizaje no supervisado**, específicamente de agrupamiento o clustering. Al no contar con una variable objetivo preestablecida (etiquetas) que indique a qué segmento pertenece cada cliente, el modelo tendrá la tarea de descubrir la estructura subyacente en los datos y agrupar a los usuarios basándose en la similitud de sus hábitos de compra.

Como posible trabajo futuro o extensión del proyecto, una vez validados los clusters, estos podrían utilizarse como etiquetas sintéticas para entrenar un modelo de aprendizaje supervisado (como Random Forest o XGBoost). Esto permitiría clasificar automáticamente a los nuevos clientes a medida que ingresan al sistema, operativizando la segmentación en tiempo real.

4. Modelos a utilizar

Para garantizar la robustez del análisis, se evaluarán y compararán los siguientes algoritmos:

- **K-Means:** Se utilizará como modelo base debido a su simplicidad, eficiencia computacional y amplio uso en la literatura para segmentaciones RFM. El hiperparámetro K se optimizará mediante el método del codo y el coeficiente de silueta.
- **Clustering Jerárquico Aglomerativo:** Permitirá visualizar la estructura topológica de los grupos mediante un dendrograma, sirviendo como validación cruzada para los resultados de K-Means sin necesidad de definir K a priori.
- **DBSCAN:** Al estar basado en densidad, es altamente robusto frente a valores atípicos y permite geometrías de clusters arbitrarias. Es fundamental para este dominio, ya que las compras mayoristas de clientes B2B representan outliers legítimos en el monto transaccional y no simples errores de carga.
- **Gaussian Mixture Models (GMM):** Se incluirá para evaluar asignaciones probabilísticas (soft clustering), lo cual aporta una visión más realista para aquellos clientes cuyos comportamientos se encuentran en la frontera entre dos segmentos.

Métricas y técnicas complementarias:

La evaluación cuantitativa se realizará utilizando el coeficiente de silueta, el índice de Davies-Bouldin y el índice de Calinski-Harabasz. No obstante, la validación cualitativa (la interpretabilidad comercial de los clusters) será el criterio definitivo de éxito. Además, se aplicará estandarización de variables

(StandardScaler) previo al modelado por distancias, y técnicas de reducción de dimensionalidad (PCA o t-SNE) para la visualización en 2D.

5. Metodología propuesta

El desarrollo del proyecto seguirá un pipeline estructurado en las siguientes fases:

1. Extracción y consolidación de la base transaccional.
2. Limpieza de datos (tratamiento de nulos, devoluciones, registros duplicados).
3. Ingeniería de variables (Cálculo de features RFM y métricas complementarias).
4. Análisis Exploratorio de Datos (EDA) y visualización.
5. Estandarización de escalas.
6. Entrenamiento de algoritmos y búsqueda de hiperparámetros.
7. Evaluación mediante métricas internas y validación de negocio.
8. Perfilado de segmentos y propuesta de acciones de retención/conversión.
9. Documentación técnica y presentación final.

6. Resultado esperado

Al finalizar el proyecto, se entregará:

- Un dataset curado y documentado con las características RFM de los clientes.
- Un modelo de clustering entrenado, validado y con sus decisiones paramétricas justificadas.
- Un diccionario de perfiles comerciales detallando el comportamiento de cada segmento.
- Un plan de acción con recomendaciones de marketing orientadas a datos.
- El código fuente completo y reproducible en Python (utilizando librerías como pandas, scikit-learn, matplotlib y seaborn), alojado en un repositorio o notebook estructurado.

Este entregable no solo cumplirá con los requisitos académicos de la materia, sino que sentará las bases lógicas y metodológicas para que una empresa del sector pueda implementar estrategias de personalización reales y medibles.