

Documentación del Conjunto de Datos

Trabajo Final de Aprendizaje Automático — Segmentación de Clientes · Ian Gallego, 2026

1. Origen y Recopilación del Dataset

El presente conjunto de datos, denominado **transacciones_ecommerce.csv**, constituye un caso de estudio integrador orientado a analizar el comportamiento transaccional de un e-commerce del rubro ferretero y de materiales de construcción. El estudio se sitúa en la matriz comercial de Tierra del Fuego y toma como referente un caso real: una empresa radicada en la ciudad de Río Grande.

Por razones de estricta confidencialidad corporativa y de protección de datos sensibles, no fue posible acceder a la base de producción de la compañía. A fin de preservar el propósito metodológico de la investigación sin comprometer información privada, se optó por **sintetizar** un conjunto de datos equivalente. Dicha síntesis se llevó a cabo mediante un script en Python (`generar_dataset.py`) gobernado por un generador aleatorio con semilla fija (`numpy.random.default_rng(42)`), lo que asegura la reproducibilidad íntegra del experimento.

Cabe subrayar que los datos resultantes no son producto de un muestreo aleatorio ingenuo: reproducen de manera deliberada las lógicas y regularidades observables en la provincia entre el 2 de junio de 2024 y el 31 de mayo de 2026. Entre ellas se incluyen el modelado de la inflación en pesos argentinos, la marcada estacionalidad de la construcción austral —con picos estivales (diciembre a marzo) y valles invernales profundos (junio a agosto)— y la concentración de la facturación en segmentos B2B (constructoras y contratistas) conforme a una distribución de Pareto.

2. Descripción Estructural del Conjunto de Datos

El dataset adopta un formato tabular estándar y se organiza en torno a las siguientes dimensiones principales:

- **Cantidad de instancias (filas):** 50.730 transacciones. A modo de nota metodológica, se conservaron intencionalmente 75 duplicados exactos para habilitar evaluaciones durante la fase de limpieza.
- **Cantidad de clientes:** 5.000 clientes únicos.
- **Características (columnas):** 9 variables de negocio.

El diccionario de datos se detalla a continuación:

- id_transaccion** (String): código alfanumérico único de cada venta (formato TX-XXXXXX), con huecos deliberados en la numeración que simulan operaciones no concretadas.
- id_cliente** (String): identificador único del cliente (formato CLI-XXXXX).
- fecha** (Date): fecha de registro de la transacción en formato YYYY-MM-DD.
- categoria_producto** (String): variable categórica nominal que agrupa la compra en 12 rubros ferreteros, con un desbalanceo realista entre ellos.
- cantidad_items** (Integer): variable numérica discreta con las unidades adquiridas por compra (rango de 1 a 300).

- 6 **monto_total** (Float): variable numérica continua que refleja el importe final en ARS; admite valores negativos para representar notas de crédito y devoluciones.
- 7 **canal_venta** (String): canal por el que ingresó la transacción (Web, App, Telefónico).
- 8 **medio_pago** (String): variable categórica con 5 métodos de pago oficiales, con variantes tipográficas y abreviaturas introducidas a modo de ruido.
- 9 **localidad** (String): variable geográfica (Río Grande, Ushuaia, Tolhuin), con variaciones intencionales de mayúsculas, espacios y errores de tipeo.

3. Diseño y Generación del Dataset Sintético

La verosimilitud del conjunto descansa sobre el generador `generar_dataset.py`, concebido bajo una premisa central: un dataset sintético sólo resulta valioso para la investigación si reproduce las regularidades estructurales del fenómeno que pretende emular, y no un mero ruido estadístico. Por ello, el script no muestrea las variables de forma independiente, sino que articula varios mecanismos generativos —inflación, estacionalidad, ciclo de vida del cliente y segmentación latente— que interactúan entre sí para producir transacciones coherentes.

3.1. Arquitectura general

El generador opera en dos niveles jerárquicos. En el primero sintetiza una población de `N_CLIENTES` clientes y asigna a cada uno un *segmento latente* que determina su intensidad de compra, su escala de gasto, su carácter B2B/B2C y su ventana de actividad. En el segundo nivel, para cada cliente se generan sus transacciones individuales, cuya fecha, categoría, cantidad y monto se derivan de las propiedades del segmento y del contexto temporal. Toda la aleatoriedad se canaliza por un único generador con semilla fija, condición necesaria para la reproducibilidad exacta del conjunto.

3.2. Modelado de la inflación

El componente inflacionario se construye como un índice acumulativo a partir de tasas mensuales del IPC argentino en fase de desinflación. Tomando como base un valor unitario en junio de 2024, cada mes se encadena multiplicativamente con su tasa, de modo que el índice crece de forma compuesta a lo largo de los 24 meses:

```
tasas_mensuales = {(2024,6): 0.046, (2024,7): 0.040, ...} # IPC mensual
indice, acum = {}, 1.0
for (y, m), t in tasas_mensuales.items():
    indice[(y, m)] = acum # índice del mes (base jun-2024 = 1,0)
    acum *= (1 + t)      # el mes siguiente arranca más caro
```

Fragmento 1. Construcción del índice de inflación acumulado.

Este índice multiplica luego el precio base de cada transacción, por lo que un mismo producto resulta progresivamente más caro en términos nominales. Tal dinámica es la que, en la etapa de modelado, obliga a **deflactar** los montos antes de comparar clientes pertenecientes a cohortes temporales distintas.

3.3. Estacionalidad y patrón semanal

La demanda dista de ser uniforme en el tiempo. Sobre la probabilidad de que una transacción ocurra en una fecha dada se aplican dos factores multiplicativos: uno *mensual*, que recoge la estacionalidad de la

construcción austral (máximos en verano, mínimos en pleno invierno), y otro *semanal*, que penaliza con fuerza los domingos. El producto de ambos pondera el muestreo de las fechas de compra dentro de la ventana activa de cada cliente, reproduciendo así tanto los ciclos anuales como el ritmo semanal del negocio.

3.4. Segmentos latentes, catálogo y formación del monto

El núcleo del realismo reside en los cinco segmentos latentes que estructuran la población (Tabla 1). Cada segmento se define por su proporción poblacional, su número esperado de transacciones, su escala de gasto, su naturaleza B2B o B2C y la amplitud típica de su ventana de actividad:

Segmento	Prop.	Tx media	Escala \$	Tipo	Ventana (días)
B2B_grande	3 %	50	2,6	B2B	720
B2B_pequeño	12 %	24	1,6	B2B	640
B2C_activo	25 %	13	1,0	B2C	600
B2C_ocasional	40 %	5,5	0,8	B2C	380
B2C_única	20 %	1,3	0,7	B2C	90

Tabla 1. Parámetros de los segmentos latentes. Estas etiquetas se emplean para generar los datos y luego se ocultan: redescubrirlas sin supervisión es, precisamente, el objetivo del clustering.

A partir de estos parámetros, el número de transacciones de cada cliente se extrae de una distribución de Poisson centrada en la media de su segmento, mientras que las cantidades por ítem siguen una distribución lognormal acoplada a la categoría —el cemento se vende a granel; las aberturas, de a una— y amplificada para los clientes B2B. El monto final integra todos estos factores en una única expresión multiplicativa:

```
qty    = int(np.ceil(rng.lognormal(mu_q, sg_q) * (1.8 if es_b2b else 1.0)))
infl   = indice[(f.year, f.month)]          # factor inflacionario del mes
ruido  = rng.lognormal(0, 0.18)            # dispersión idiosincrática
monto  = precio_base * infl * qty * ruido * escala_segmento
```

Fragmento 2. Composición del monto de cada transacción.

La convivencia de unos pocos clientes B2B de altísima frecuencia y gasto con una larga cola de compradores ocasionales reproduce la concentración de Pareto característica del negocio. Esa estructura latente es, en definitiva, la que el análisis de segmentación deberá recuperar sin acceso a las etiquetas originales.

3.5. Inyección de imperfecciones correlacionadas

Por último, sobre el conjunto ya formado se introducen imperfecciones deliberadas y, sobre todo, *correlacionadas* —en contraste con el ruido uniforme de un dataset ingenuo—. Se generan devoluciones (montos negativos), *outliers* legítimos de obra (montos amplificados por un factor), valores nulos concentrados en el canal telefónico (que emulan fallas de pasarela), inconsistencias ortográficas en *localidad* y *medio_pago*, y duplicados exactos por doble envío de formulario. Estas anomalías son las que motivan y dan sentido a la etapa de preprocesamiento descrita en la sección 4.

3.6. Reproducibilidad y escalabilidad

El generador está parametrizado: tanto la cantidad de clientes (- -n) como la semilla (- -seed) son argumentos de línea de comandos. Ello permite escalar el conjunto sin alterar sus propiedades estadísticas. La versión documentada en este informe corresponde a **5.000 clientes** (≈ 50.700 transacciones), obtenida con la semilla 42.

4. Calidad de los Datos y Preprocesamiento Requerido

Fiel a un entorno empresarial crudo, el conjunto incorpora diversas imperfecciones de manera correlacionada. Para su correcta ingesta por los algoritmos posteriores resulta necesario un pipeline de preprocesamiento estructurado —implementado con librerías especializadas como Pandas— orientado a las siguientes tareas:

- **Tratamiento de valores nulos:** se identificó aproximadamente un 0,7 % de nulos en `monto_total`, concentrados en el canal telefónico (falla de pasarela que aconseja su eliminación). Asimismo, se detectaron nulos en `medio_pago` ($\sim 1,2$ %), `localidad` ($\sim 0,4$ %) y `categoria_producto` ($\sim 0,26$ %), que requieren imputación por moda o por valores canónicos como “Desconocido”.
- **Gestión de outliers y anomalías:** existen cerca de 150 compras masivas de características atípicas (hasta $\sim \$37$ M) correspondientes a obras grandes, que demandan winsorización o documentación específica. En paralelo, se hallaron 392 registros con montos negativos (devoluciones) que deben netearse o filtrarse según el enfoque del análisis RFM (Recency, Frequency, Monetary value).
- **Normalización de textos:** ciertas variables categóricas exigen limpieza. El campo `localidad` requiere `.str.strip().str.title()` para resolver espacios residuales y faltas ortográficas (como “Tohluin”), mientras que `medio_pago` debe mapearse a su forma canónica para corregir entradas como “transf.” o “T. crédito”.
- **Eliminación de duplicados:** ejecución de rutinas de limpieza que purgan los 75 registros idénticos detectados.

5. Alcances y Limitaciones del Dataset Sintético

La decisión de trabajar con datos sintéticos conlleva ventajas evidentes —reproducibilidad, ausencia de riesgos de confidencialidad— pero también limitaciones que conviene explicitar con honestidad metodológica:

- 1 **Todo se deriva de supuestos, no de mediciones.** Los precios base, la amplitud estacional, el mix de categorías y la proporción de clientes B2B son estimaciones plausibles, no valores observados. Un conjunto real reflejaría las particularidades de ese negocio puntual —por ejemplo, una ferretería que vende un 40 % de cemento por un convenio con una constructora—, matices que ninguna heurística previa logra anticipar.
- 2 **Las colas de la distribución resultan “demasiado prolijas”.** Los outliers se generan multiplicando por un factor controlado, mientras que los datos reales exhiben rarezas ajenas a una lognormal: una transacción de \$0,01 por un ajuste contable, un cliente que compró 250 bolsas de cemento y devolvió 248, o duplicados parciales (mismo pedido con distinto medio de pago). El generador produce anomalías de catálogo; la realidad produce anomalías que no figuraban en ningún catálogo.

- 3 Ausencia de dependencia temporal real (autocorrelación).** Las fechas de compra se muestrean de manera independiente, en tanto que un cliente real presenta rachas: inicia una obra y compra cinco veces en dos semanas, para luego desaparecer durante tres meses. Esa estructura de “ráfagas” dependiente de la trayectoria es de las más difíciles de falsificar y de las primeras en delatar datos sintéticos en un análisis de recencia.
- 4 Sólo existen las correlaciones programadas de forma explícita.** Se modelaron las relaciones canal–pago y segmento–categoría, pero en datos reales todo se correlaciona con todo de maneras sutiles: la localidad con la categoría (Ushuaia demanda más calefacción), el día del mes con el medio de pago (la quincena trae más efectivo) o el clima de la semana con las ventas.
- 5 Inflación aproximada y sin shocks.** El índice describe un sendero suave, cuando la realidad atravesó saltos, congelamientos y picos puntuales. Faltan, además, los eventos exógenos que siempre emergen en datos reales: un Black Friday, una rotura de stock de dos semanas o la irrupción de un competidor que hunde las ventas durante un mes.
- 6 Elementos no fabricables de forma fidedigna.** SKUs reales, nombres y, en especial, la suciedad genuina que produce la entrada de datos a través de múltiples sistemas fusionados de manera imperfecta. Es posible imitar esa suciedad, pero la sintética es estadística, mientras que la real es histórica.